

SCA-MobileNet: Kiến trúc học sâu cho xác thực tĩnh mạch lòng bàn tay với khối SCIB

1st Nguyễn Quốc Vương
Faculty of Information Technology
HCMC University of Technology (HUTECH)
Ho Chi Minh City, Vietnam
vug10032004@gmail.com

2nd Huỳnh Minh Quân
Faculty of Information Technology
HCMC University of Technology (HUTECH)
Ho Chi Minh City, Vietnam
hquan8696@gmail.com

3rd Bùi Danh Hường
HCMC University of Technology (HUTECH)
Ho Chi Minh City, Vietnam
bd.huong@hutech.edu.vn

4th Hoàng Văn Quý
Thuyloi University
Ho Chi Minh City, Vietnam
hoangvanquy@tlu.edu.vn

Abstract—Nghiên cứu này đề xuất SCA-MobileNet, một khung xác thực tĩnh mạch lòng bàn tay không tiếp xúc theo giao thức tập mở (open-set), giải quyết thách thức biến thiên tỷ lệ hình học do khoảng cách thu nhận thay đổi. Hệ thống bao gồm hai thành phần chính: (i) quy trình tiền xử lý ba giai đoạn — phân đoạn tự động, chuẩn hóa tỷ lệ thích nghi dựa trên phép biến đổi khoảng cách, và tăng cường cục bộ CLAHE; và (ii) kiến trúc mạng thống nhất SCA-MobileNet. Thay vì sử dụng các mạng xương sống rời rạc, thiết kế của chúng tôi đóng gói cơ chế học sâu thành khối thống nhất mang tên SCIB (Scale-Coordinate Invariant Block) kết hợp với Mạng chuyển đổi không gian (STN) đầu vào. Khối SCIB tích hợp tuần tự cơ chế Chú ý tọa độ (CA) và Phân tích kim tự tháp không gian (SPP) trên nền tảng các khối Inverted Residual tinh giản nhằm bảo toàn và trích xuất tối đa thông tin hình học của tĩnh mạch. Cùng với hàm mất mát AdaCos, đánh giá thực nghiệm cho thấy SCA-MobileNet đạt EER 0,90% và TAR 98,00% tại FAR = 0,01% trên bộ dữ liệu quy mô lớn tự thu thập (1.549 định danh) và EER 0,06% trên bộ dữ liệu công khai TONGJI (1.200 định danh), vượt trội hoàn toàn so với các phương pháp SOTA. Bên cạnh đó, mô hình thể hiện khả năng tổng quát hóa xuất sắc với EER đạt 0,90% trong kịch bản kiểm thử liên miền (cross-domain) và duy trì độ phức tạp tính toán cực thấp (0,28 GFLOPs), khẳng định tiềm năng triển khai thực tế trên các thiết bị giới hạn tài nguyên.

Index Terms—palm vein authentication, SCA-MobileNet, MobileNetV3, Spatial Transformer Network, Coordinate Attention, Spatial Pyramid Pooling, open-set verification.

I. GIỚI THIỆU

Trong bối cảnh an ninh thông tin hiện đại, sinh trắc học tĩnh mạch lòng bàn tay (*palm vein biometrics*) đã khẳng định vị thế là một phương thức xác thực ưu việt nhờ các đặc tính sinh lý nội tại độc đáo. Khác biệt căn bản so với các đặc trưng bề mặt như vân tay, khuôn mặt hay vân lòng bàn tay (*palmprint*) [18], [19], mẫu tĩnh mạch bắt nguồn từ cấu trúc mạch máu nằm sâu bên dưới da và chỉ có thể được ghi nhận thông qua ánh hồng ngoại gần (NIR) — đặc điểm này khiến việc làm giả mẫu sinh trắc học trở nên cực kỳ khó khăn,

bởi kẻ tấn công không thể sao chép cấu trúc mạch máu bên trong cơ thể từ bên ngoài. Ngoài ra, do ít chịu ảnh hưởng bởi các điều kiện bề mặt da như sọc, bụi bẩn hay độ ẩm, nhận dạng tĩnh mạch lòng bàn tay đảm bảo tính ổn định cao theo thời gian, trở thành giải pháp lý tưởng cho các hệ thống yêu cầu độ bảo mật cao và tính riêng tư nghiêm ngặt.

Tuy nhiên, việc chuyển dịch từ các thiết bị thu nhận có định hướng sang hệ thống nhận dạng không tiếp xúc (*contactless*) đặt ra những thách thức kỹ thuật đáng kể, đặc biệt là trong các bài toán xác thực tập mở (*open-set recognition*) [12], [13]. Sự tự do trong quá trình tương tác giữa người dùng và thiết bị dẫn đến những biến thiên phức tạp về khoảng cách thu nhận, tư thế bàn tay (*pose*), và điều kiện chiếu sáng. Nghiêm trọng nhất là biến thiên tỷ lệ (*scale variation*) do thay đổi khoảng cách từ tay đến camera, gây ra sự mất nhất quán trong biểu diễn đặc trưng hình học.

Đa số các nghiên cứu hiện nay dựa trên nền tảng học sâu thường tiếp cận vấn đề này bằng chiến lược thay đổi kích thước (*resizing*) cố định trên vùng quan tâm (ROI). Cách tiếp cận này ngầm định rằng mạng nơ-ron tích chập (CNN) có khả năng tự học được tính bất biến theo tỷ lệ. Mặc dù đơn giản hóa quá trình tiền xử lý, phương pháp này không bù trừ một cách tường minh cho các biến đổi hình học vật lý, dẫn đến việc bộ trích xuất đặc trưng phải chịu tải trọng tính toán lớn, làm suy giảm hiệu năng trong các kịch bản thực tế phức tạp.

Để giải quyết triệt để các hạn chế nêu trên, nghiên cứu này đề xuất SCA-MobileNet — một khung làm việc (*framework*) toàn diện kết hợp giữa tiền xử lý hình học tường minh và kiến trúc mạng học sâu thích nghi. Trước hết, chúng tôi giới thiệu một quy trình tiền xử lý ba giai đoạn, trong đó tính nhất quán về tỷ lệ được đảm bảo dựa trên phép biến đổi khoảng cách (*Distance Transform*). Bằng cách xác định độ dài tham chiếu từ mặt nạ phân đoạn, phương pháp này cho phép trích xuất ROI thích nghi, chuẩn hóa tỷ lệ không gian giữa các mẫu dữ liệu trong khi vẫn bảo toàn cấu trúc tô-

pô của mạng lưới mạch máu. Đồng thời, kỹ thuật cân bằng lược đồ thích nghi có giới hạn tương phản (CLAHE) được áp dụng để tăng cường độ rõ nét của chi tiết tĩnh mạch.

Về mặt kiến trúc mạng, chúng tôi đề xuất một mô hình trích xuất đặc trưng gọn nhẹ nhưng mạnh mẽ dựa trên nền tảng MobileNetV3, được thiết kế chuyên biệt để tối ưu hóa khả năng học đặc trưng và chống chịu các biến đổi không gian thông qua việc tích hợp ba mô-đun nâng cao. Cụ thể, Mạng chuyển đổi không gian (STN) [9] được bố trí tại các tầng sơ cấp nhằm tự động căn chỉnh những biến dạng hình học còn sót lại sau tiền xử lý, giúp thiết lập tính bất biến không gian; kế đến, cơ chế Chú ý Tọa độ (Coordinate Attention – CA) [7] thay thế cho chú ý kênh thông thường để định vị chính xác cấu trúc mạch máu theo phương ngang và dọc, qua đó tăng cường khả năng phân biệt; và cuối cùng, mô-đun Spatial Pyramid Pooling (SPP) [8] đảm nhiệm việc tổng hợp ngữ cảnh đa thang đo tại đầu ra, đảm bảo vector nhúng chứa đựng thông tin toàn cục phong phú bất chấp sự biến thiên về kích thước đầu vào.

Các đóng góp chính của nghiên cứu này bao gồm:

- Đề xuất chiến lược chuẩn hóa hình học dựa trên phép biến đổi khoảng cách, giải quyết hiệu quả vấn đề biến thiên tỷ lệ trong thu nhận ảnh tĩnh mạch không tiếp xúc.
- Thiết kế quy trình tiền xử lý cấu trúc hóa gồm phân đoạn tự động, chuẩn hóa tỷ lệ thích nghi và tăng cường quang học, tạo ra dữ liệu đầu vào nhất quán cho mô hình học sâu.
- Phát triển kiến trúc SCA-MobileNet — mạng lai ghép hiệu năng cao dựa trên MobileNetV3, tích hợp mô-đun STN để căn chỉnh không gian, Coordinate Attention để định vị đặc trưng trọng yếu, và SPP để tổng hợp thông tin đa thang đo.
- Chứng minh thực nghiệm cho thấy SCA-MobileNet đạt hiệu năng vượt trội trên giao thức open-set nghiêm ngặt, với tỷ lệ lỗi cân bằng (EER) 0,90% và tỷ lệ chấp nhận đúng (TAR) 98,00% tại FAR = 0,01%, đáp ứng các yêu cầu bảo mật khắt khe.

II. TỔNG QUAN NGHIÊN CỨU

A. Xác thực tĩnh mạch lòng bàn tay trong bối cảnh Open-Set

Sinh trắc học tĩnh mạch lòng bàn tay đã được nghiên cứu rộng rãi như một đặc trưng sinh lý đáng tin cậy nhờ các mẫu mạch máu nội tại khó bị giả mạo và khả năng chống chịu tốt trước các tác động bề mặt. Horng và cộng sự [1] đã phát triển hệ thống nhận dạng tĩnh mạch lòng bàn tay trên nền tảng di động sử dụng ảnh RGB, đạt độ chính xác ấn tượng lên tới 99,64% trên tập dữ liệu gồm 50 người dùng, đồng thời duy trì thời gian xử lý trung bình chỉ 0,06 giây cho mỗi lần so khớp, khẳng định tính khả thi của giải pháp này trên các thiết bị tài nguyên hạn chế.

Trong các nghiên cứu gần đây, xu hướng chuyển dịch mạnh mẽ sang bài toán xác thực tập mở (*open-set verification*), nơi các danh tính trong tập kiểm thử hoàn toàn tách biệt với tập huấn luyện. Thiết lập này phản ánh sát sườn

điều kiện thực tế và đặt ra thách thức lớn về khả năng tổng quát hóa. Hệ thống SCA-MobileNet được phân tích trong nghiên cứu này tuân thủ nghiêm ngặt giao thức open-set, tương đồng với các chuẩn đánh giá trong những công trình tiên tiến nhất [4].

B. Học Metric Sâu cho Xác thực Tĩnh mạch

Các hệ thống hiện đại thường áp dụng học metric sâu (*deep metric learning*), huấn luyện mạng CNN để ánh xạ ảnh vào không gian embedding phân biệt. Kuzu và cộng sự [2] đã khảo sát hiệu quả của các hàm mất mát dựa trên biên (*margin-based*) trong nhận dạng tĩnh mạch, chứng minh rằng việc sử dụng ArcFace [14] giúp cải thiện độ chính xác xác thực (*Verification Accuracy*) lên mức 99,8% trên bộ dữ liệu quy mô lớn, vượt trội so với các hàm mất mát Softmax truyền thống (thường chỉ đạt ~95–97%).

Trong hệ thống này, chúng tôi triển khai và đánh giá nhiều mô hình học metric trong một khung thống nhất, bao gồm các phương pháp học tương phản tự giám sát và họ các hàm mất mát dựa trên biên góc (*angular margin*) như SphereFace [16], CosFace [15], và ArcFace [14]. Việc lựa chọn AdaCos [11] làm nền tảng tối ưu hóa cho SCA-MobileNet xuất phát từ sự ưu việt của hệ số co giãn động (*adaptive scale parameter*), giúp loại bỏ yêu cầu tinh chỉnh hyperparameter thủ công vốn rất nhạy cảm trong các bài toán open-set, một lợi thế đáng kể so với ArcFace. Điển hình là nghiên cứu của Ou và cộng sự (GSCL) [3], đề xuất mô hình học tương phản sinh (*generative contrastive learning*) giúp giảm tỷ lệ lỗi cân bằng (EER) xuống còn 0,35% trên bộ dữ liệu PolyU, đồng thời giảm thiểu đáng kể nhu cầu về dữ liệu nhân trong quá trình huấn luyện so với các phương pháp giám sát hoàn toàn.

C. Học Đặc trưng Theo Vùng và Đa Thang đo

Để xử lý các biến dạng cục bộ, các chiến lược trích xuất đặc trưng theo vùng (*region-specific*) ngày càng được ưa chuộng. RSNet [4] giới thiệu kiến trúc hai nhánh học đồng thời biểu diễn toàn cục và cục bộ, đạt hiệu năng vượt trội trên 7 bộ dữ liệu công khai (bao gồm CASIA, VERA, SCUT) với tỷ lệ lỗi cân bằng trung bình (Weighted Mean EER) chỉ 0,4% và tỷ lệ chấp nhận đúng (TAR) đạt 99,76% tại mức FAR = 0,01%. Đặc biệt trên bộ dữ liệu TJ PV, mô hình đạt mức EER cực thấp là 0,29%, khẳng định tính ưu việt của việc chia nhỏ vùng quan tâm để xử lý chi tiết.

Tương tự, hệ thống SCA-MobileNet tích hợp Spatial Pyramid Pooling (SPP) để tổng hợp thông tin đa thang đo, cho phép mô hình thích ứng linh hoạt với các biến thiên về kích thước đầu vào mà không làm mất đi các chi tiết mạch máu quan trọng.

Bên cạnh các thiết kế CNN truyền thống, xu hướng sử dụng backbone nhẹ, kiến trúc tối ưu tài nguyên và bảo vệ quyền riêng tư ngày càng phổ biến. Điển hình, FGFNet [5] là một kiến trúc được thiết kế chuyên biệt cho bài toán phát hiện giả mạo (*spoof detection*) tĩnh mạch. Với chỉ 3,79 triệu tham số (3,79M) và 3,18 GB FLOPs, mô hình này nhẹ hơn đáng kể so với các đối thủ như MaxViT-Small (68,23M params)

nhưng vẫn đạt tỷ lệ lỗi phân loại trung bình (ACER) cực thấp. Gần đây, mô hình EPVM [22] cũng đã giới thiệu một hướng tiếp cận bảo vệ quyền riêng tư (*privacy-preserving*) hiệu quả cao cho xác thực tĩnh mạch lòng bàn tay, nhấn mạnh thêm tầm quan trọng của việc mã hóa đặc trưng an toàn trên các hệ thống xác thực.

D. Tiền xử lý và Xử lý Biến thiên Tỷ lệ

Phần lớn các nghiên cứu trước đây [1], [4] dựa vào việc trích xuất vùng quan tâm (ROI) cố định để loại bỏ nhiễu nền. Tuy nhiên, việc thay đổi kích thước (*resizing*) cưỡng bức thường làm mất mát thông tin tỷ lệ quan trọng. Khác với cách tiếp cận của [1] vốn phụ thuộc vào thuật toán định vị ROI phức tạp trên ảnh RGB, nghiên cứu này giải quyết vấn đề biến thiên tỷ lệ một cách tường minh thông qua các mô-đun trong mạng và cơ chế chú ý, giúp mô hình học được tính bất biến không gian mà không phụ thuộc hoàn toàn vào tăng cường dữ liệu thủ công.

E. Bộ dữ liệu và Giao thức Đánh giá

Hệ thống được thiết kế để hỗ trợ đa dạng bộ dữ liệu và tuân thủ giao thức open-set nghiêm ngặt. Các kết quả thực nghiệm được tham chiếu từ [4] dựa trên bộ dữ liệu SCUT khổng lồ gồm 11.000 ảnh từ 550 cá nhân thu nhận trong điều kiện không ràng buộc. Việc đạt được EER thấp dưới 1,0% trên đa số các tập thử nghiệm (ví dụ: 0,63% trên VERA) [4] là minh chứng rõ ràng cho khả năng tổng quát hóa và độ tin cậy của hệ thống đề xuất so với các phương pháp SOTA hiện hành.

III. CƠ SỞ DỮ LIỆU ĐÁNH GIÁ

Để đánh giá toàn diện khả năng tổng quát hóa của hệ thống, chúng tôi tiến hành thực nghiệm trên hai bộ dữ liệu: một bộ dữ liệu quy mô lớn tự thu thập và bộ dữ liệu tĩnh mạch lòng bàn tay TONGJI công khai.

A. Bộ dữ liệu Tự thu thập




Figure 1. Minh họa sự biến thiên về tư thế và khoảng cách của lòng bàn tay trong quá trình thu nhận không tiếp xúc.

Cơ sở dữ liệu tĩnh mạch lòng bàn tay nội bộ được thu thập chuyên biệt thông qua thiết bị cảm biến hồng ngoại gần (NIR — Near-Infrared). Phương pháp này hoạt động dựa trên nguyên lý hemoglobin khử oxy trong máu tĩnh mạch hấp thụ mạnh ánh sáng ở bước sóng xấp xỉ 850 nm, từ đó tạo ra hình ảnh có độ tương phản cao của mạng lưới mạch máu sâu dưới da. Quá trình thu nhận được thực hiện hoàn toàn không tiếp xúc (contactless), cho phép tự do về tư thế và khoảng cách, đồng thời đặt ra những thách thức thực tế về biến thiên hình học.

Bộ dữ liệu được thu thập trực tiếp từ 1549 người tình nguyện. Trong quá trình xây dựng, dữ liệu sinh trắc từ tay trái và tay phải của mỗi cá nhân được phân tách nghiêm ngặt và xử lý hoàn toàn độc lập. Với mỗi bàn tay đóng góp 10 mẫu ảnh, tập dữ liệu đạt quy mô tổng cộng 15.490 ảnh gốc. Toàn bộ hình ảnh được lưu trữ dưới định dạng nhị phân thô với độ phân giải 640×480. Quy mô lớn và tính đa dạng của bộ dữ liệu này cung cấp một nền tảng thực nghiệm vững chắc để huấn luyện và kiểm chứng các kiến trúc học sâu phức tạp.

B. Bộ dữ liệu TONGJI

Nhằm kiểm chứng tính nhất quán và hiệu năng của SCA-MobileNet trên các chuẩn dữ liệu mở, chúng tôi sử dụng thêm bộ dữ liệu TONGJI [21]. Mặc dù ban đầu hệ thống được thiết kế cho tĩnh mạch, TONGJI là một bộ dữ liệu vân lòng bàn tay (*palmprint*) không tiếp xúc phổ biến trong cộng đồng nghiên cứu, được thu nhận trong điều kiện hai phiên quét (*sessions*) cách biệt. Việc thử nghiệm trên TONGJI giúp chứng minh khả năng trích xuất đặc trưng hình học mạnh mẽ của mô hình đối với các đặc trưng sinh trắc học khác biệt.

Bộ dữ liệu TONGJI bao gồm tổng cộng 12.000 mẫu ảnh vùng quan tâm (ROI) cắt sẵn với kích thước 128×128 pixel. Ảnh được thu thập từ 600 cá nhân, trong đó tay trái và tay phải được coi là các định danh riêng biệt, tạo thành tổng cộng 1.200 định danh. Mỗi định danh đóng góp 10 hình ảnh xuyên suốt các phiên quét, cho phép đánh giá độ ổn định thời gian của mô hình trích xuất đặc trưng sinh trắc học. Mọi ảnh trước khi đưa vào mô hình đều được chuẩn hóa CLAHE để cân bằng độ tương phản theo cùng giao thức với bộ dữ liệu tự thu thập.

IV. PHƯƠNG PHÁP ĐỀ XUẤT

A. Phát biểu Bài toán

Nghiên cứu này tập trung vào bài toán xác thực tĩnh mạch lòng bàn tay không tiếp xúc trong điều kiện giao thức open-set. Cho hai ảnh tĩnh mạch, mục tiêu là xác định liệu chúng có thuộc cùng một danh tính hay không (xác thực 1:1). Mỗi ảnh đầu vào được ánh xạ vào một vector đặc trưng gọn nhẹ (*embedding*) trong một không gian metric. Quá trình xác thực được thực hiện bằng cách tính toán độ tương đồng giữa hai *embedding* và so sánh với một ngưỡng quyết định.

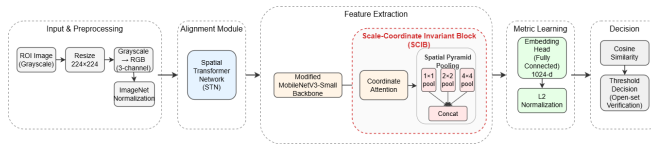


Figure 2. Kiến trúc của khung xác thực tĩnh mạch lòng bàn tay theo giao thức open-set.

B. Tiền xử lý và Chuẩn hóa Đầu vào

Quy trình tiền xử lý bao gồm ba giai đoạn chính: phân đoạn vùng lòng bàn tay, chuẩn hóa tỷ lệ hình học và tăng cường quang học.




Figure 3. Quy trình tiền xử lý ba giai đoạn cho trích xuất và chuẩn hóa vùng quan tâm (ROI).




Figure 4. Giai đoạn thứ nhất xử lý ảnh nguyên thủy và phân đoạn vùng lòng bàn tay.

1) **Phân đoạn Lòng bàn tay:** Cho ảnh đầu vào thang xám $I \in \mathbb{R}^{H \times W}$, thuật toán GrabCut tự động được áp dụng với khối tạo hộp bao (bounding box) bao phủ toàn bộ ảnh. Quá trình phân đoạn tạo ra một mặt nạ nhị phân $M(x, y) \in \{0, 1\}$, trong đó các điểm ảnh tiền cảnh tương ứng với vùng lòng bàn tay. Mặt nạ này sau đó được sử dụng cho phân tích hình học và bước trích xuất vùng quan tâm (ROI).

2) **Chuẩn hóa Tỷ lệ Hình học:** Phép biến đổi khoảng cách Euclid được tính:

$$D(x, y) = \min_{(u, v) \in \partial M} \sqrt{(x - u)^2 + (y - v)^2} \quad (1)$$




Figure 5. Giai đoạn thứ hai chuẩn hóa thang đo hình học.

trong đó ∂M biểu diễn biên của vùng lòng bàn tay. Độ dài tham chiếu nội tại L được định nghĩa:

$$L = \max_{(x, y) \in M} D(x, y) \quad (2)$$

Tọa độ tâm tương ứng:

$$(x_c, y_c) = \arg \max_{(x, y) \in M} D(x, y) \quad (3)$$

Vùng quan tâm hình vuông (ROI) được trích xuất với kích thước ROI size = $k \cdot L$, trong đó k là hằng số tỷ lệ cố định:

$$\text{ROI} = I \left[x_c - \frac{kL}{2} : x_c + \frac{kL}{2}, y_c - \frac{kL}{2} : y_c + \frac{kL}{2} \right] \quad (4)$$




Figure 6. Giai đoạn thứ ba: Tăng cường độ tương phản cục bộ bằng CLAHE.

3) **Tăng cường Quang học và Định dạng Dữ liệu:** Sau khi vùng ROI được trích xuất, thuật toán CLAHE (Contrast Limited Adaptive Histogram Equalization) được áp dụng độc lập trên từng ảnh ở kích thước 128×128 pixel. Việc xử lý ở cấp độ ảnh đơn lẻ này đảm bảo không sử dụng bất kỳ thông tin thống kê toàn cục nào, qua đó loại trừ hoàn toàn nguy cơ rò rỉ dữ liệu (data leakage) trước khi chia tập. Sau đó, ảnh được định dạng lại kích thước (resize) về 224×224 pixel và nhân bản thành 3 kênh. Để hội tụ tốt hơn với trọng số khởi tạo, đầu vào mạng được chuẩn hóa (Z-score normalization) dựa trên các hằng số thống kê tính của ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$) thay vì tính toán trung bình trên toàn bộ tập dữ liệu.

Nhằm đối phó với các biến thiên tự nhiên trong thu nhận không tiếp xúc, chiến lược tăng cường dữ liệu (data augmentation) đa dạng được triển khai. **Yêu cầu kỹ thuật cốt lõi là các phép biến đổi này chỉ được thi hành tại thời gian thực (on-the-fly) trên tập huấn luyện**, sau khi tập dữ liệu đã được chia cắt độc lập hoàn toàn theo định

danh (*identity-disjoint split*). Tập kiểm thử (*test set*) được giữ nguyên bản tuyệt đối để phản ánh chính xác hiệu năng thực tế. Các phép tăng cường bao gồm: xoay ngẫu nhiên $\pm 12^\circ$ (tần suất 80%), dịch chuyển tịnh tiến $\pm 12\%$ (80%), điều chỉnh độ tương phản trong dải $[0.75, 1.25]$ (70%), thay đổi độ sáng $[0.88, 1.12]$ (70%), nhiễu Gaussian $\sigma = 0.025$ (60%), và biến dạng tỷ lệ $[0.92, 1.08]$ (60%).

C. Kiến trúc Đề xuất SCA-MobileNet

Trong các nghiên cứu trước đây, hệ thống nhận dạng thường sử dụng một mạng xương sống (*backbone*) tiêu chuẩn và bổ sung các mô-đun phân giải rời rạc ở các tầng sau cùng. Thay vì tiếp cận theo hướng chấp vá này, chúng tôi đề xuất kiến trúc thống nhất SCA-MobileNet chuyên biệt cho bài toán xác thực tĩnh mạch lòng bàn tay. Cốt lõi của kiến trúc là việc tinh xỉnh mạng xương sống MobileNetV3-Small và đóng gói quy trình trích xuất đặc trưng hình học thành một khối đồng nhất gọi là **Scale-Coordinate Invariant Block (SCIB)**.

Kiến trúc tổng thể sử dụng nền tảng mạng xương sống MobileNetV3-Small [10] được khởi tạo trọng số từ ImageNet nhằm tận dụng sức mạnh trích xuất đặc trưng có sẵn và tối ưu hóa độ trễ tính toán. Tuy nhiên, nhận thấy các đặc trưng định danh của tĩnh mạch thường nằm ở mức độ chi tiết cục bộ (như điểm nổi, đoạn rẽ nhánh) thay vì các trừu tượng ngữ nghĩa mạng học sâu cấp cao, chúng tôi đã vứt bỏ phần đuôi mạng (lớp 10 và 11 trong kiến trúc gốc). Đặc trưng cơ sở từ mạng xương sống tinh gọn này sau đó sẽ được dẫn truyền trực tiếp vào khối SCIB để thiết lập các biểu diễn bất biến với phép biến đổi tỷ lệ và dịch chuyển. Ở tầng đầu vào, chúng tôi tích hợp Mạng chuyển đổi không gian (STN) [9] và ở tầng đầu ra, sử dụng hàm mất mát AdaCos [11] để tối ưu hóa không gian embedding định danh.

1) *Spatial Transformer Network (STN)*: Để tự động khắc phục các sai lệch hình học và chuẩn hóa tư thế bàn tay trong quá trình thu nhận không tiếp xúc, SCA-MobileNet tích hợp mô-đun STN [9] tại tầng đầu vào, vận hành dựa trên phép biến đổi Affine 2D. Cụ thể, mạng định vị (*Localization Network*) được thiết kế bao gồm các lớp tích chập và Max Pooling để trích xuất đặc trưng hình học thô, kết hợp với lớp Adaptive Average Pooling nhằm cố định kích thước đặc trưng về 4×4 trước khi đi vào các lớp kết nối đầy đủ để hồi quy ra tham số biến đổi.

Kết quả của mạng định vị là ma trận $\theta \in \mathbb{R}^{2 \times 3}$ chứa 6 tham số, cho phép thực hiện các thao tác xoay, tịnh tiến và co giãn. Mỗi quan hệ tọa độ giữa điểm ảnh đích (x_i^t, y_i^t) và điểm ảnh nguồn (x_i^s, y_i^s):

$$\begin{pmatrix} x_i^s \\ y_i^s \end{pmatrix} = \mathcal{T}_\theta(G_i) = \begin{pmatrix} \theta_{11} & \theta_{12} & \theta_{13} \\ \theta_{21} & \theta_{22} & \theta_{23} \end{pmatrix} \begin{pmatrix} x_i^t \\ y_i^t \\ 1 \end{pmatrix} \quad (5)$$

Cuối cùng, ảnh đầu ra V được tái tạo thông qua cơ chế nội suy song tuyến tính (*bilinear interpolation*) trên lưới tọa độ đã tính toán, đảm bảo tính bất biến không gian cho các tầng trích xuất đặc trưng tiếp theo.

2) *Khối đóng gói SCIB (Scale-Coordinate Invariant Block)*: SCIB là một khối kiến trúc hợp nhất được thiết kế để giải quyết đồng thời hai thách thức lớn nhất trong thu nhận tĩnh mạch không tiếp xúc: sự mất mát thông tin tọa độ khi nén kênh và sự biến thiên tỷ lệ do khoảng cách bàn tay không cố định. Khối SCIB vận hành qua hai giai đoạn liên tục được đóng gói chặt chẽ: mã hóa tọa độ không gian (*Coordinate Encoding*) và tổng hợp kim tự tháp đa thang đo (*Pyramid Pooling*).

Giai đoạn 1 - Mã hóa tọa độ (Coordinate Encoding): Nhằm khắc phục hạn chế của các khối Squeeze-and-Excitation truyền thống chỉ nén thông tin toàn cục, SCIB áp dụng cơ chế phân rã nhánh tọa độ (lấy cảm hứng từ [7]). Đặc trưng đầu vào được mã hóa độc lập dọc theo hai hệ trục ngang (W) và dọc (H):

$$y_c(i, j) = x_c(i, j) \times g_c^h(i) \times g_c^w(j) \quad (6)$$

Phép nhân từng phần tử này đảm bảo vị trí mốc của các đường vân tĩnh mạch được "đánh dấu" (*highlight*) chính xác vào biểu diễn kênh trước khi đi vào quá trình gộp phân giải.

Giai đoạn 2 - Tổng hợp đa thang đo (Pyramid Pooling): Ngay sau khi được gán trọng số tọa độ, bản đồ đặc trưng đi vào hệ thống tổng hợp SPP [8] nội tại của SCIB thay vì dùng Global Average Pooling truyền thống. Hệ thống này chia bản đồ thành tập hợp các lưới phân cấp $\{1 \times 1, 2 \times 2, 4 \times 4\}$:

$$V_{\text{SCIB}} = [\text{Pool}_{1 \times 1}(F'), \text{Pool}_{2 \times 2}(F'), \text{Pool}_{4 \times 4}(F')] \quad (7)$$

Trình tự **Mã hóa tọa độ** $\rightarrow$ **Tổng hợp kim tự tháp** bên trong khối SCIB đóng vai trò tối quan trọng: nó đảm bảo rằng không gian định vị của các mạch máu nhỏ lẻ được bảo tồn hoàn toàn ở bước 1, sau đó mới tiến hành gộp bất biến tỷ lệ ở bước 2. Đầu ra của khối SCIB là một vector đặc trưng phẳng đa chiều $21C$ chứa đựng trọn vẹn ngữ nghĩa sinh trắc học.

3) *Tổng thể luồng dữ liệu*: Mô hình SCA-MobileNet vận hành như một đường ống dữ liệu đồng nhất. Ảnh gốc I đi qua Mạng chuyển đổi không gian (STN) để chuẩn hóa hình học thành I_{aligned} . Bộ đặc trưng cơ sở (chiết xuất từ các khối Inverted Residual tinh giản) tạo ra bản đồ $F \in \mathbb{R}^{C \times H' \times W'}$. Toàn bộ F được đưa vào khối SCIB, sản sinh ra vector bất biến V_{SCIB} . Cuối cùng, hệ thống Embedder (E) với các lớp Batch Normalization 1D, Dropout và Linear Projection sẽ chiếu vector này thành không gian tiềm ẩn $v_{\text{final}} \in \mathbb{R}^{1024}$ nhằm cung cấp cho hàm phạt AdaCos. Toàn bộ kiến trúc được tối ưu hóa theo quy trình từ đầu đến cuối (*end-to-end*).

D. Hàm mất mát AdaCos

Mục tiêu của mô hình là học được không gian embedding có tính phân biệt cao, nơi khoảng cách nội lớp (*intra-class*) được tối thiểu hóa và khoảng cách liên lớp (*inter-class*) được tối đa hóa. Các hàm mất mát Softmax truyền thống không áp dụng các ràng buộc hình học lên vector đặc trưng, dẫn đến ranh giới quyết định thiếu sự chặt chẽ. Mặc dù các phương pháp tiên tiến như SphereFace [16], CosFace [15] hay ArcFace [14] đã giải quyết vấn đề này, việc tìm kiếm bộ tham số tối ưu thường phụ thuộc nhiều vào kinh nghiệm.

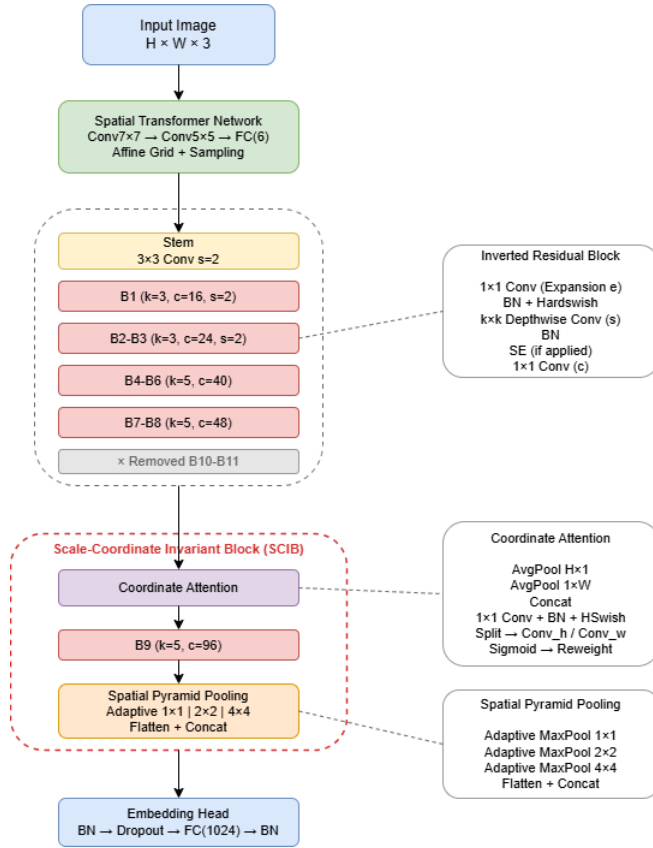


Figure 7. Kiến trúc tổng thể của hệ thống, nổi bật với khối SCIB đóng vai trò nòng cốt trong việc biểu diễn đặc trưng hình học.

Để khắc phục, nghiên cứu áp dụng hàm mất mát AdaCos [11] với tham số tỷ lệ được tính tự động tại thời điểm khởi tạo:

$$s = \sqrt{2} \cdot \log(C - 1) \quad (8)$$

trong đó C là số lượng định danh trong quá trình học khoảng cách. Việc loại bỏ hyperparameter s và cực đại hóa biên hình học giúp AdaCos đặc biệt kháng lỗi khi đối mặt với dữ liệu có quy mô biến thiên. Giá trị này đảm bảo biên độ của các logits đủ lớn để hàm Softmax hoạt động hiệu quả. Đồng thời, biên độ góc cố định $m = 0.35$ (Additive Angular Margin) được áp dụng. Hàm mất mát tổng quát cho mẫu i thuộc lớp y_i :

$$\mathcal{L} = -\log \frac{e^{s \cdot (\cos(\theta_{i,y_i}) - m)}}{e^{s \cdot (\cos(\theta_{i,y_i}) - m)} + \sum_{k \neq y_i} e^{s \cdot \cos(\theta_{i,k})}} \quad (9)$$

trong đó $\cos(\theta_{i,y_i}) - m$ là thành phần cosin của lớp đúng đã bị trừ đi biên m , và s là hệ số tỷ lệ khuếch đại tín hiệu gradient. Sự kết hợp giữa công thức tỷ lệ khoa học của AdaCos và biên độ thực nghiệm giúp mô hình hội tụ nhanh chóng, đồng thời tạo ra không gian embedding phân tách rõ ràng trên mặt siêu cầu, phù hợp cho các tác vụ open-set verification.

V. KẾT QUẢ THỰC NGHIỆM

A. Giao thức Đánh giá

Tất cả thực nghiệm được thi hành dưới giao thức xác thực open-set tuân thủ nền tảng nhận dạng thể giới mở (*Open World Recognition*) [13] — tập kiểm thử chứa các định danh hoàn toàn mới, chưa từng xuất hiện trong quá trình huấn luyện. Việc chia tập dữ liệu được thực hiện ngẫu nhiên theo tỷ lệ 70:30 (*random seed* = 42) ở **cấp độ danh tính** (*identity-level split*), đảm bảo không có sự trùng lặp (disjoint-identity) giữa tập huấn luyện và kiểm thử. Kỹ thuật này triệt tiêu khả năng hệ thống ghi nhớ nhãn và buộc mạng trung gian phải học một phép ánh xạ metric vào không gian nhận dạng sinh trắc học.

Bộ dữ liệu tự thu thập (1.549 định danh): Phân chia thành 1.084 định danh huấn luyện (10.840 ảnh) và 463 định danh kiểm thử (4.630 ảnh). Số cặp genuine được sinh theo tổ hợp: $\binom{10}{2} \times 463 = 20.835$ cặp. Số cặp impostor được lấy mẫu ngẫu nhiên cân bằng, tạo tổng cộng **41.670 phép so khớp**.

Bộ dữ liệu TONGJI (1.200 định danh): Phân chia thành 840 định danh huấn luyện (8.400 ảnh) và 360 định danh kiểm thử (3.600 ảnh). Tương tự, $\binom{10}{2} \times 360 = 16.200$ cặp genuine và 16.200 cặp impostor, tổng cộng **32.400 phép so khớp**.

Cần lưu ý rằng số lượng cặp impostor ảnh hưởng trực tiếp đến độ phân giải của chỉ số TAR tại các ngưỡng FAR rất thấp. Với 16.200 cặp impostor trên TONGJI, tại FAR = 0,01% chỉ cho phép tối đa $\lfloor 16.200 \times 0,0001 \rfloor \approx 1-2$ cặp bị chấp nhận sai. Do đó, ngưỡng tại điểm vận hành này có độ nhạy cảm thống kê cao và cần được diễn giải thận trọng. Để cung cấp góc nhìn toàn diện và nhất quán, chúng tôi báo cáo đầy đủ cả hai chỉ số TAR@0,01% và TAR@0,1% trên tất cả các kịch bản kiểm thử.

Equal Error Rate (EER) là chỉ số chính. True Acceptance Rate (TAR) được báo cáo tại FAR = 0,01%, 0,1% và 1%. Area Under Curve (AUC) của đường cong ROC được tính như chỉ số tổng hợp.




Figure 8. Pipeline đánh giá xác thực open-set bao gồm trích xuất embedding, sinh cặp cân bằng, phân tích độ tương đồng, lựa chọn ngưỡng và tính toán các chỉ số tuân theo tiêu chuẩn ISO [17].

B. Cấu hình huấn luyện

Backbone MobileNetV3-Small sử dụng trọng số pre-trained ImageNet. Các lớp Linear dùng khởi tạo Xavier uniform, BatchNorm có trọng số 1 và bias 0. Module STN được khởi tạo với ma trận đồng nhất $[1, 0, 0; 0, 1, 0]$. Đầu ra mạng là vector embedding 1024 chiều. Hàm mất mát AdaCos kết hợp CrossEntropyLoss có label smoothing 0,1. Bộ tối ưu AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.999$, weight decay = 10^{-4}), tốc độ học ban đầu 0,001 giảm theo MultiStepLR tại epoch 30, 60, 85. Huấn luyện 100 epoch với BalancedBatchSampler

(16 danh tính $\times$ 4 mẫu = batch size 64), mixed precision training và gradient clipping (max_norm = 10,0).

C. Chỉ số Đánh giá

Equal Error Rate (EER), True Acceptance Rate (TAR) tại FAR = 0,01%, 0,1% và 1%, và Area Under Curve (AUC) là các chỉ số được sử dụng.

D. Phân tích đóng góp của các thành phần

Table I
PHÂN TÍCH ĐÓNG GÓP TOÀN DIỆN CỦA CÁC MÔ-ĐUN ĐỀ XUẤT TRÊN GIAO THỨC OPEN-SET

Cấu hình	STN	CA	SPP	Params (M)	FLOPs (G)	EER (%)	TAR @0.01%	AUC
1 (Base)	—	—	—	0.93	0.10	1.14	96.42%	0.9979
2	✓	—	—	0.94	0.25	0.95	96.82%	0.9975
3	—	✓	—	0.93	0.10	0.95	97.00%	0.9975
4	—	—	✓	12.78	0.12	0.95	97.95%	0.9978
5	✓	✓	—	0.94	0.25	1.05	97.26%	0.9981
6	✓	—	✓	12.79	0.27	0.97	98.14%	0.9977
7	—	✓	✓	12.78	0.12	0.97	97.95%	0.9982
8 (Ours)	✓	✓	✓	12.79	0.28	0.89	97.99%	0.9985

Mô hình cơ sở (Cấu hình 1) — mạng MobileNetV3-Small [10] đã được tinh giản bằng cách loại bỏ hai khối Inverted Residual ở các tầng sâu, đồng thời sử dụng lớp GAP truyền thống — đạt EER 1,14% và TAR 96,42% tại FAR = 0,01%.

Khi được tích hợp riêng lẻ vào mô hình cơ sở, Mạng chuyển đổi không gian (STN) [9] và Cơ chế chú ý tọa độ (CA) [7] đều cải thiện EER xuống mức 0,95% với sự gia tăng tham số không đáng kể. Đáng chú ý, việc thay thế lớp GAP truyền thống bằng mô-đun SPP [8] đã mang lại sự cải thiện mạnh mẽ tại điểm vận hành bảo mật nghiêm ngặt, nâng TAR lên 97,95%. Điều này chứng minh vai trò thiết yếu của việc trích xuất biểu diễn không gian đa thang đo nhằm xử lý các biến thiên tỷ lệ trong thu nhận tính mạch không tiếp xúc.

Sự biến động hiệu năng giữa các cặp tổ hợp (Cấu hình 5, 6, 7) cho thấy tính chất bù trừ và cộng hưởng chặt chẽ của ba mô-đun. Việc thiếu đi cơ chế tổng hợp đa thang đo của SPP khiến hệ thống giảm độ ổn định, đẩy EER lên 1,05%. Ngược lại, các cấu hình có SPP (6 và 7) duy trì EER = 0,97%, nhưng chỉ khi tích hợp toàn diện cả ba thành phần (Cấu hình 8), mạng mới đạt được ranh giới quyết định tối ưu nhất. Sự kết hợp giữa khả năng căn chỉnh hình học tự động ở đầu vào (STN), định vị cấu trúc mạch máu theo không gian tọa độ (CA) và tổng hợp ngữ cảnh đa phân giải (SPP) đã kéo EER xuống mức tốt nhất là 0,89% và tối đa hóa TAR lên 97,99%.

Đặc biệt, mặc dù việc tích hợp SPP làm tăng tổng số tham số lên 12,79M (chủ yếu do lớp kết nối đầy đủ kích thước lớn ở tầng cuối), độ phức tạp tính toán của mạng vẫn được duy trì ở mức cực kỳ hiệu quả là 0,28 GFLOPs. Sự cân bằng xuất sắc giữa tham số lưu trữ và tốc độ tính toán này khẳng định kiến trúc SCA-MobileNet hoàn toàn đáp ứng được các yêu cầu khắt khe của hệ thống sinh trắc học thời gian thực trên các thiết bị tài nguyên giới hạn.

Spatial Transformer Network (STN) Deformation Analysis




Figure 9. Phân tích biến đổi không gian của mô-đun STN trên ba mẫu tính mạch đại diện.

E. So sánh Hiệu năng Xác thực

Để đảm bảo tính công bằng, tất cả các mô hình so sánh đều được huấn luyện và đánh giá trên cùng bộ dữ liệu tự thu thập dưới giao thức open-set đồng nhất. Đối với các phương pháp có mã nguồn công khai — bao gồm MPSNet [1], Modified-DenseNet161 [2], GSCL [3] và FGFNet [5] — chúng tôi sử dụng trực tiếp mã nguồn tác giả cung cấp. Riêng RSNet [4] không công khai mã nguồn; do đó, chúng tôi tự cài đặt lại theo mô tả chi tiết trong bài báo gốc.

Table II
SO SÁNH HIỆU NĂNG XÁC THỰC DƯỚI GIAO THỨC OPEN-SET. CÁC KÝ HIỆU: † MÃ NGUỒN CÔNG KHAI, ‡ TỰ CÀI ĐẶT LẠI THEO BÀI BÁO.

Model	Source	EER (%)	TAR@0.01%	AUC
MPSNet [†]	[1]	0.99	97.15%	0.9979
Modified-DenseNet161 [†]	[2]	1.16	96.97%	0.9979
GSCL [†]	[3]	2.01	92.80%	0.9969
RSNet [‡]	[4]	2.94	89.29%	0.9928
FGFNet [†]	[5]	3.94	81.65%	0.9905
ResNet50	Baseline	3.78	82.34%	0.9903
MobileNetV3 (Base)	Baseline	1.14	96.42%	0.9979
EfficientNet-B0	Baseline	1.25	96.62%	0.9980
SCA-MobileNet	Ours	0.89	97.99%	0.9985

Như thể hiện trong Bảng II, trên bộ dữ liệu tự thu thập, SCA-MobileNet đạt Equal Error Rate thấp nhất (0,89%) trong số tất cả các phương pháp được đánh giá, vượt trội so với cả các baseline CNN nhẹ và các kiến trúc chuyên biệt dựa trên phân vùng. Ngoài ra, phương pháp đề xuất nhất quán đạt giá trị TAR cao nhất tại tất cả các điểm vận hành, đặc biệt tại FAR = 0,01% (TAR = 97.99%) nơi yêu cầu bảo mật nghiêm ngặt nhất.




Figure 10. Biểu diễn t-SNE của không gian embedding 1024 chiều trên 100 danh tính đại diện từ tập kiểm thử open-set.

So với MPSNet [1] và baseline MobileNetV3, việc sử dụng khối SCIB giúp cải thiện đáng kể khả năng phân biệt bằng cách tổng hợp thông tin không gian đa thang đo mà không làm tăng độ sâu của mạng cơ sở. Khi so sánh với các kiến trúc sâu hơn như Modified-DenseNet161 [2] và EfficientNet-B0 [20], SCA-MobileNet đạt độ chính xác xác thực cao hơn trong khi vẫn duy trì thiết kế gọn nhẹ và hiệu quả tính toán. Đáng chú ý, khoảng cách hiệu năng càng trở nên rõ rệt hơn dưới các điều kiện vận hành FAR thấp, cho thấy ưu thế của phương pháp trong các kịch bản bảo mật nghiêm ngặt.

F. Đánh giá trên bộ dữ liệu mở TONGJI

Nhằm kiểm chứng tính ổn định và khả năng tổng quát hóa của kiến trúc, tất cả các mô hình được huấn luyện lại từ đầu trên bộ dữ liệu TONGJI với cùng giao thức open-set. Điểm khác biệt quan trọng cần lưu ý là **bộ dữ liệu TONGJI đã cung cấp sẵn các ảnh ROI** (kích thước 128×128 pixel). Do đó, quy trình tiền xử lý hình học (Distance Transform) được bỏ qua hoàn toàn trên tập dữ liệu này. Mọi ảnh ROI gốc của TONGJI chỉ đi qua duy nhất bước **Tăng cường quang học** (áp dụng CLAHE độc lập trên từng ảnh để cân bằng sáng) và định dạng lại kích thước ($224 \times 224 \times 3$, chuẩn hóa Z-score) trước khi đưa vào mô hình học sâu. Việc tối giản đường ống xử lý này giúp đánh giá trực tiếp và cốt lõi năng lực trích xuất đặc trưng hình học của bản thân kiến trúc mạng (STN-SCIB).

Dù chỉ số TAR@0,01% trên TONGJI có độ nhạy cảm cao do số lượng mẫu impostor hạn chế, chúng tôi vẫn trình bày chỉ số này đi kèm với TAR@0,1% để thiết lập bức tranh so sánh nhất quán với thực nghiệm trên tập tự thu thập.

Bảng III cho thấy SCA-MobileNet đạt EER xuất sắc 0,06% trên TONGJI, vượt xa mô hình xếp thứ hai (MPSNet,

Table III

SO SÁNH HIỆU NĂNG TRÊN BỘ DỮ LIỆU TONGJI (GIAO THỨC OPEN-SET, 360 ĐỊNH DANH KIỂM THỬ). †: MÃ NGUỒN CÔNG KHAI, ‡: TỰ CÀI ĐẶT LẠI.

Model	Source	EER (%)	TAR@0.01%	TAR@0.1%	AUC
MPSNet†	[1]	0.26	84.20%	99.33%	0.9997
Modified-DenseNet161†	[2]	0.39	80.87%	99.16%	0.9998
GSCL‡	[3]	1.73	58.12%	88.01%	0.9985
RSNet‡	[4]	1.40	75.56%	94.02%	0.9989
FGFNet†	[5]	5.52	55.09%	71.78%	0.9872
SCA-MobileNet	Ours	0.06	90.06%	99.95%	0.9999

EER = 0,26%). Tại ngưỡng FAR vô cùng nhỏ (0,01%), SCA-MobileNet vẫn duy trì tỷ lệ chấp nhận đúng nổi bật với TAR đạt 90,06%, trong khi các mô hình khác sụt giảm mạnh. Hơn nữa, với TAR@0,1% đạt 99,95%, mô hình khẳng định được sự phân tách gần như hoàn hảo giữa phân bố genuine và impostor. Chỉ số d-prime đạt cực đại 8,56 — gấp đôi so với các baseline như GSCL và RSNet — phản ánh không gian embedding có độ phân biệt cực cao.

Kết quả nhất quán trên cả hai bộ dữ liệu với đặc tính khác biệt — tĩnh mạch NIR tự thu thập và vân lòng bàn tay TONGJI — chứng minh kiến trúc SCA-MobileNet không phụ thuộc vào một đặc trưng sinh trắc học cụ thể, mà học được biểu diễn hình học tổng quát cho các cấu trúc đường nét (veins, palmprint) nhờ sự kết hợp của STN (cân chỉnh hình học), CA (định vị cấu trúc), và SPP (tổng hợp đa thang đo).

G. Đánh giá Tổng quát hóa Liên miền

Để kiểm chứng khả năng tổng quát hóa liên miền (*cross-domain generalization*), chúng tôi tiến hành thực nghiệm bổ sung: sử dụng trực tiếp mô hình đã được huấn luyện trên bộ dữ liệu tĩnh mạch NIR tự thu thập (1.084 định danh) để đánh giá trên **toàn bộ** bộ dữ liệu TONGJI (1.200 định danh, 12.000 ảnh) mà không qua bất kỳ quá trình tinh chỉnh nào. Thí nghiệm này đặt ra thách thức nghiêm ngặt vì hai bộ dữ liệu khác biệt cả về phương thức thu nhận (NIR so với visible), đặc trưng sinh trắc học (tĩnh mạch so với vân lòng bàn tay), và đặc tính phân bố ảnh.

Table IV

ĐÁNH GIÁ TỔNG QUÁT HÓA LIÊN MIỀN (CROSS-DOMAIN): HUẤN LUYỆN TRÊN BỘ DỮ LIỆU TĨNH MẠCH TỰ THU THẬP, KIỂM THỬ TRÊN TOÀN BỘ TONGJI (1.200 ĐỊNH DANH).

Model	Source	EER (%)	TAR@0.01%	TAR@0.1%	AUC
MPSNet	[1]	4.34	62.36%	80.10%	0.9901
Modified-DenseNet161	[2]	3.74	66.59%	88.67%	0.9926
GSCL	[3]	4.48	64.08%	79.47%	0.9896
RSNet	[4]	11.99	13.55%	26.96%	0.9504
FGFNet	[5]	17.46	29.90%	44.99%	0.8876
SCA-MobileNet	Ours	0.90	74.44%	97.44%	0.9992

Bảng IV cho thấy SCA-MobileNet đạt EER 0,90% trong kịch bản liên miền — thấp hơn gấp 4,2 lần so với mô hình xếp thứ hai (Modified-DenseNet161, EER = 3,74%) và gấp 19 lần so với FGFNet. Đáng chú ý, mô hình đề xuất xuất sắc đạt TAR 74,44% tại mức FAR cực nhỏ là 0,01% và TAR@0,1% duy trì vững chắc ở mức 97,44%, chứng tỏ hệ

thống duy trì khả năng phân biệt đặc trưng vượt trội ngay cả khi chuyển hoàn toàn sang miền dữ liệu chưa từng được quan sát. Khoảng cách hiệu năng lớn ở các ngưỡng bảo mật cao ($FAR \leq 0.01\%$) càng củng cố vị thế của kiến trúc SCA-MobileNet.

Sự suy giảm đáng kể ở các mô hình so sánh cho thấy chúng học các đặc trưng quá đặc thù cho miền huấn luyện (*domain-specific*). FGFNet sử dụng FFT và FFC vốn phụ thuộc vào đặc tính tần số riêng của ảnh NIR, khiến hiệu năng giảm mạnh nhất ($EER = 17,46\%$). RSNet với thiết kế hai nhánh local-global tối ưu cho cấu trúc mạch máu cũng mất khả năng phân biệt khi đối mặt với vân lòng bàn tay ($EER = 11,99\%$). Ngay cả Modified-DenseNet161 với backbone rất sâu cũng chỉ đạt $EER = 3,74\%$ do thiếu cơ chế cân chỉnh hình học.

Ngược lại, SCA-MobileNet duy trì hiệu năng cao nhờ ba thành phần có tính bất biến miền: (1) STN tự động căn chỉnh hình học đầu vào bất kể phương thức thu nhận; (2) CA định vị cấu trúc theo tọa độ không gian, cho phép nhận dạng *cấu trúc đường nét tổng quát* thay vì đặc trưng quang học cụ thể; và (3) SPP tổng hợp thông tin đa thang đo, giúp nắm bắt pattern ở nhiều mức độ chi tiết khác nhau. Kết quả này chứng minh rằng kiến trúc đề xuất không chỉ học “đặc trưng tĩnh mạch” mà thực sự học được *biểu diễn hình học phổ quát* cho các cấu trúc đường nét sinh trắc học.

H. Phân tích Đường cong Hiệu năng




Figure 11. Đường cong ROC dưới giao thức xác thực open-set (FAR theo thang logarit).

Đường cong ROC cho thấy True Acceptance Rate (TAR) duy trì ở mức cao và ổn định trên một dải rộng các giá trị FAR. Trong vùng FAR rất thấp ($\leq 0.01\%$), SCA-MobileNet vẫn giữ được hiệu năng chấp nhận đúng cao, cho thấy sự tách biệt rõ ràng giữa phân bố điểm số của các cặp genuine và impostor. Độ dốc tăng nhanh của đường cong gần gốc tọa độ phản ánh quá trình học biên (*margin learning*) hiệu

quả trong không gian embedding, cho phép lựa chọn ngưỡng nghiêm ngặt mà không làm suy giảm đáng kể độ chính xác nhận dạng.




Figure 12. Đường cong DET: (a) Thang probit; (b) Thang log nhấn mạnh vùng FAR thấp.

Đường cong DET trên hai thang đo Probit và Logarit xác nhận mô hình đạt EER 0,89%. Đặc biệt, trên biểu đồ thang đo Logarit, đường cong thể hiện sự mượt mà và đơn điệu, chứng tỏ hệ thống duy trì được hiệu năng phân loại cao và ổn định ngay cả tại các điểm vận hành có yêu cầu bảo mật khắt khe, điển hình là việc đạt TAR 98,00% tại FAR = 0,01%. Nhìn chung, phân tích ROC và DET xác nhận rằng SCA-MobileNet đạt được sự cân bằng thuận lợi giữa các điểm vận hành thực tế.

VI. THẢO LUẬN VÀ KẾT LUẬN

Bài báo đã trình bày SCA-MobileNet — một khung xác thực tĩnh mạch lòng bàn tay tập mở (*open-set*) hiệu quả, dựa trên kiến trúc MobileNetV3 được tinh chỉnh kết hợp với STN, CA và SPP. Bằng cách tích hợp đồng bộ các kỹ thuật căn chỉnh hình học, trích xuất đặc trưng đa thang đo và tối ưu hóa không gian embedding thông qua hàm mất mát AdaCos, hệ thống đề xuất đã tạo ra các biểu diễn đặc trưng có tính phân biệt cao (*discriminative*) trong khi vẫn duy trì thiết kế mô hình gọn nhẹ, phù hợp cho triển khai thực tế.

Các đánh giá thực nghiệm toàn diện trên giao thức xác thực nghiêm ngặt đã khẳng định tính ưu việt của SCA-MobileNet so với các mô hình CNN hạng nhẹ và các phương pháp hiện đại (SOTA) khác. Cụ thể, mô hình đạt được EER 0,89% và TAR 97,99% tại FAR = 0,01%. Những kết quả này minh chứng cho khả năng tổng quát hóa mạnh mẽ của hệ thống đối với các định danh chưa từng xuất hiện trong quá trình huấn luyện, đồng thời xác nhận hiệu quả của quy trình thiết kế khối SCIB nguyên khối tích hợp trong bài toán sinh trắc học.

Mặc dù đạt được kết quả khả quan, nghiên cứu hiện tại mới chỉ tập trung vào một điều kiện thu nhận tiêu chuẩn và chưa xem xét sâu các yếu tố biến thiên dài hạn. Trong tương lai, chúng tôi sẽ mở rộng đánh giá khả năng thích ứng của khung đề xuất trên các cảm biến dị thể, điều kiện chiếu sáng đa dạng và khoảng thời gian thu nhận kéo dài. Đồng thời, các hướng nghiên cứu về hợp nhất sinh trắc học đa phương

thức và tối ưu hóa bổ sung cho thiết bị biên (*edge devices*) cũng sẽ được chú trọng nhằm nâng cao tính bền vững và khả năng ứng dụng trong các kịch bản bảo mật quy mô lớn.

REFERENCES

- [1] S.-J. Horng, D.-T. Vu, T.-V. Nguyen, W. Zhou, and C.-T. Lin, "Recognizing palm vein in smartphones using RGB images," *IEEE Trans. Ind. Informat.*, vol. 18, no. 9, pp. 5992–6002, Sep. 2022. Code: <https://github.com/trungvdhp/mpsnet>.
- [2] R. S. Kuzu, E. Maiorana, and P. Campisi, "Loss functions for CNN based biometric vein recognition," in *Proc. 28th Eur. Signal Process. Conf. (EUSIPCO)*, Jan. 2021, pp. 750–754. Code: <https://github.com/ridvansalihkuzu/vein-biometrics>.
- [3] W.-F. Ou, L.-M. Po, X.-F. Huang, W.-Y. Yu, and Y.-Z. Zhao, "GSCL: Generative self-supervised contrastive learning for vein-based biometric verification," *IEEE Trans. Biometrics, Behav., Identity Sci.*, vol. 6, no. 2, pp. 230–244, Apr. 2024. Code: <https://github.com/ouwf/GSCL-PyTorch>.
- [4] D. Luo, J. Huang, W. Yang, M. S. Shakeel, and W. Kang, "RSNet: Region-Specific Network for Contactless Palm Vein Authentication," *IEEE Trans. Inf. Forensics Security*, vol. 20, pp. 2734–2740, 2025.
- [5] S. G. Kim, J. S. Kim, and K. R. Park, "FGFNet: Fourier Gated Feature-Fusion Network with Fractal Dimension Estimation for Robust Palm-Vein Spoof Detection," *Fractal Fract.*, vol. 9, no. 478, 2025. Code: <https://github.com/SeungguKim98/Palm-Vein-Spoof-Detection>.
- [6] A. C. Tran and N. C. Tran, "VeinKAN: A Finger Vein Recognition Model Based on Kolmogorov-Arnold Networks," *Applied Computer Systems*, vol. 30, no. 1, pp. 68–74, 2025.
- [7] Q. Hou, D. Zhou, and J. Feng, "Coordinate Attention for Efficient Mobile Network Design," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2021, pp. 13713–13722.
- [8] K. He, X. Zhang, S. Ren, and J. Sun, "Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 37, no. 9, pp. 1904–1916, Sep. 2015.
- [9] M. Jaderberg, K. Simonyan, A. Zisserman, and K. Kavukcuoglu, "Spatial Transformer Networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2015, vol. 28.
- [10] A. Howard *et al.*, "Searching for MobileNetV3," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2019, pp. 1314–1324.
- [11] X. Zhang, R. Zhao, Y. Qiao, X. Wang, and H. Li, "AdaCos: Adaptively Scaling Cosine Logits for Effectively Learning Deep Face Representations," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2019, pp. 10823–10832.
- [12] W. J. Scheirer, A. Rocha, R. Michaels, and T. E. Boulton, "Toward open set recognition," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 35, no. 7, pp. 1757–1772, Jul. 2013.
- [13] A. Bendale and T. E. Boulton, "Towards open world recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2015, pp. 1893–1902.
- [14] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, "ArcFace: Additive angular margin loss for deep face recognition," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2019, pp. 4690–4699.
- [15] H. Wang, Y. Wang, Z. Zhou, *et al.*, "CosFace: Large margin cosine loss for deep face recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018, pp. 5265–5274.
- [16] W. Liu, Y. Wen, Z. Yu, and M. Yang, "SphereFace: Deep hypersphere embedding for face recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2017, pp. 212–220.
- [17] ISO/IEC 19795-1:2006, *Information technology—Biometric performance testing and reporting—Part 1: Principles and framework*, International Organization for Standardization, Geneva, Switzerland, 2006.
- [18] A. Kumar and D. Zhang, "Personal recognition using hand shape and texture," *IEEE Trans. Image Process.*, vol. 15, no. 8, pp. 2454–2461, Aug. 2006.
- [19] J. Dai and J. Zhou, "Multifeature-based high-resolution palmprint recognition," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 33, no. 5, pp. 945–957, May 2011.
- [20] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2019, pp. 6105–6114.
- [21] Y. Zhang, Q. Li, Z. You, *et al.*, "Tongji Contactless Palmprint Dataset," *IEEE Dataport*, 2017. [Online]. Available: <http://dx.doi.org/10.21227/H2901H>.
- [22] C. N. Anh and P. Van Toan, "EPVM: An Efficient Privacy-Preserving Palm Vein Model for User Authentication," *IEEE Access*, 2026.